cell

📝 流程详解与阶段性交付物

以下是流程中每个步骤的详细拆解。

阶段一：原始数据统计与“可信锚点库”构建

目标： 不进行任何“删除”操作，仅对全量原始数据进行统计分析，以识别出哪些LAC和CellID是稳定且可信的“锚点”。

- **步骤 1.1: 运营商网络识别与标记**
  - **描述：** 这是您提到的关键一步。根据 `mcc` 和 `mnc` 字段，为每条记录打上网络归属标签。
  - **主要字段：** `mcc`, `mnc`, `tech` (4G/5G)
  - **规则：**
    - `mcc=460`, `mnc` in (00, 02, 07, 08) → `network_group = 'CM_Group'` (移动/铁通/广电)
    - `mcc=460`, `mnc` in (01, 06, 09) → `network_group = 'CU_Group'` (联通)
    - `mcc=460`, `mnc` in (03, 05, 11) → `network_group = 'CT_Group'` (电信)
    - *注意：* 4G/5G的共建共享可能需要更细的规则（例如NSA/SA），但 `network_group` 是第一层抽象。
  - **输出：** 带有 `network_group` 字段的原始数据。
- **步骤 1.2: LAC 统计库构建**
  - **描述：** 按 `lac` 进行分组，统计其稳定性、活跃度和数据量。
  - **主要字段：** `GROUP BY (network_group, tech, lac)`
  - **规则（统计指标）：**
    - `record_count`: 总上报次数
    - `distinct_cellid_count`: 关联的CellID数量
    - `distinct_device_count`: 关联的设备数（如果APP有设备ID）
    - `first_seen_date`: 首次上报日期
    - `last_seen_date`: 最后上报日期
    - `active_days`: 活跃天数
  - **输出：** `LAC_Stats_DB`

- **步骤 1.3: CellID 统计库构建**
  - **描述：** 按 `lac` + `cellid` 分组，统计其GPS聚集情况。
  - **主要字段：** `GROUP BY (network_group, tech, lac, cellid)`
  - **规则（统计指标）：**
    - `record_count` : 总上报次数
    - `valid_gps_count` : 有效GPS的上报次数
    - `gps_cluster_center` : 对所有有效GPS点进行聚类（如DBSCAN或K-Means）计算出的中心点。
    - `gps_cluster_radius` : GPS簇的半径（用于后续漂移判断）。
  - **输出：** `CellID_Stats_DB`
- **步骤 1.4: 生成“可信主库”（Master Lib)**
  - **描述：** 基于统计库，设定阈值，筛选出真正可信的LAC和CellID。
  - **主要字段：** `LAC_Stats_DB` , `CellID_Stats_DB`
  - **规则（可调试参数）：**
    - **可信LAC (Master_LAC_Lib):** `active_days > N` (例如: 3天) 且 `record_count > M` (例如: 1000次)。
    - **可信CellID (Master_CellID_Lib):** `record_count > X` (例如: 50次) 且 `valid_gps_count > Y` (例如: 10次) 且其 `lac` 必须在 `Master_LAC_Lib` 中。
  - **输出：** `Master_LAC_Lib` (可信LAC库), `Master_CellID_Lib` (可信CellID库，包含计算出的 `gps_cluster_center`)

> **本阶段报表 (用于调试):**

- **LAC 统计报告：** Top 1000 LAC (按 `record_count` 排序)， `active_days` 分布直方图。
- **CellID 统计报告：** `record_count` vs `valid_gps_count` 散点图， `gps_cluster_radius` 分布图（帮您确定GPS漂移阈值）。

阶段二：原始数据清洗、纠正与补齐

目标： 使用阶段一生成的“可信库”，重新遍历所有原始数据（包括APP上报、 `ss1` 、第三方数据），对每一条记录进行验证、纠正、补齐和标记。

- **步骤 2.1: 逐条记录验证与处理**
  - **描述：** 这是您在需求中描述的核心逻辑。
  - **主要字段：** `record_id` , `lac` , `cellid` , `gps` , `data_source` (APP/SS1/...)
  - **规则（为每条记录打上状态标签）：**

    i. **Case A (完美匹配):** `(lac, cellid)` 均在 `Master_CellID_Lib` 中。
        - **动作:** 标记 `status = 'Verified'`。
    ii. **Case B (LAC错误 / 可纠正):** `cellid` 在 `Master_CellID_Lib` 中，但 `lac` 不匹配。
        - **动作:** 标记 `status = 'Corrected_LAC'`，并将该记录的 `lac` *修正*为 `Master_CellID_Lib` 中的正确 `lac`。
    iii. **Case C (新CellID / 待观察):** `cellid` 不在库中，但 `lac` 在 `Master_LAC_Lib` 中。
        - **动作:** 标记 `status = 'New_CellID_Candidate'`。
    iv. **Case D (未知数据 / 暂不处理):** `lac` 和 `cellid` 均不在可信库中。
        - **动作:** 标记 `status = 'Unverified_Omitted'`。（即您提到的“标记为其他人用于后续研究”）
  - **输出:** 带有 `status` 和 `corrected_lac` 字段的数据流。
- **步骤 2.2: GPS 漂移检测**
  - **描述:** 利用 `Master_CellID_Lib` 中计算好的 `gps_cluster_center`。
  - **主要字段:** `record_gps`, `Master_CellID_Lib.gps_cluster_center`
  - **规则（可调试参数 `R`）:**
    - 对于 `status = 'Verified'` 或 `'Corrected_LAC'` 的记录:
    - 计算 `distance(record_gps, gps_cluster_center)`。
    - 如果 `distance > R` (例如: 5公里)，则标记 `gps_status = 'Drift'`。
    - 否则，标记 `gps_status = 'Verified'`。
  - **输出:** 带有 `gps_status` 标记的数据流。
- **步骤 2.3: 生成清洗补齐库**
  - **描述:** 将处理后的数据（仅保留 `status` 不是 `'Unverified_Omitted'` 的）存入新库。
  - **主要字段:** `record_id`, `original_lac`, `corrected_lac`, `cellid`, `gps`, `gps_status`, `data_source`, `status`, (以及信号强度、时间等原始字段)
  - **输出:** `Cleaned_Augmented_DB`

> **本阶段报表 (用于调试):**

- **清洗补齐效果报告:**
  - `status` 字段的分布饼图 (多少是 `Verified`, 多少是 `Corrected_LAC` ...)。
  - `gps_status` 字段的分布饼图 (多少是 `Drift` ...)。
  - 按 `data_source` (APP/SS1/第三方) 交叉分析，查看不同来源的数据质量。

阶段三：基站层级（eNodeB）构建与 GPS 修正

目标： 这是您的“全局GPS修正阶段”。从 `CellID` 聚合到 `eNodeB/gNodeB`，计算出更准确的基站GPS，并用它来反向补齐 `CellID` 的空GPS。

- **步骤 3.1: 基站ID转换**
  - **描述：** 将 `CellID` 转换为其所属的基站ID（`eNodeB` 或 `gNodeB`）。
  - **主要字段：** `cellid`, `tech`
  - **规则：**
    - **4G (eNodeB):** `eNodeB_ID = floor(cellid / 256)`。`Sector_ID = cellid % 256`。
    - **5G (gNodeB):** 规则可能更复杂（取决于 `cellid` 的位数），但逻辑相同。
  - **输出：** `Cleaned_Augmented_DB` 中增加 `bs_id` (基站ID) 和 `sector_id` 字段。
- **步骤 3.2: 计算基站 (BS) 中心GPS**
  - **描述：** 基站的物理位置是固定的。通过聚合其下所有 `CellID` 的 *有效GPS*（`gps_status = 'Verified'`），可以得到基站的精确位置。
  - **主要字段：** `GROUP BY (bs_id)`
  - **规则：**
    - 收集 `bs_id` 对应的所有 `Verified` GPS 点。
    - 计算这些点的中位数或聚类中心，得到 `bs_gps_center`。
  - **输出：** `Master_BS_Library` (包含 `bs_id`, `bs_gps_center`, `associated_lac`, `cellid_count`)。
- **步骤 3.3: 修正 LAC 中心GPS (可选但推荐)**
  - **描述：** 您的原始思路是先算LAC的GPS。现在我们有了更准的基站GPS，可以用基站GPS来计算LAC的GPS，精度更高。
  - **主要字段：** `GROUP BY (lac)`
  - **规则：** 聚合该 `lac` 下所有 `bs_gps_center`，计算其中心点，得到 `lac_gps_center_refined`。
  - **输出：** `Master_LAC_Lib` 中更新/增加 `lac_gps_center_refined` 字段。
- **步骤 3.4: 回填 CellID 的空GPS**
  - **描述：** 这是您提到的关键补齐步骤。
  - **主要字段：** `Cleaned_Augmented_DB`, `Master_BS_Library`
  - **规则：**
    - 遍历 `Cleaned_Augmented_DB` 中 `gps` 为空或 `gps_status = 'Drift'` 的记

    - 录：`Master_BS_Library` 中查找该记录 `bs_id` 对应的 `bs_gps_center`。
    - **动作：** 将 `bs_gps_center` 填充到该记录的 `gps` 字段，并标记 `gps_source = 'Augmented_from_BS'`。
  - **输出：** `Final_Master_DB` (最终的、GPS完整的主数据库)。

> **本阶段报表 (用于调试):**

- **GPS补齐报告：** `gps_source` 字段的分布（多少是原始Verified，多少是Augmented_from_BS）。
- **基站分布图：** 在地图上绘制 `Master_BS_Library` 中的所有 `bs_gps_center`，检查其合理性。

阶段四：属性库生成与变更监测 (您的后续工作)

目标： 基于 `Final_Master_DB`，构建您后续分析所需的属性库。

- **步骤 4.1: eNodeB/gNodeB 属性库**
  - **描述：** 聚合基站的特征。
  - **字段：** `bs_id`, `gps`, `lac`, `cellid_count` (下挂小区数), `tech` (4G/5G/混合), `first_seen`, `last_seen`。
- **步骤 4.2: CellID 属性库**
  - **描述：** 聚合小区的特征。
  - **字段：** `cellid`, `bs_id`, `gps`, `lac`, `avg_signal_strength`, `record_count`。
- **步骤 4.3: 变更监测**
  - **描述：** 通过对比不同时间周期的 `Master_BS_Library` 和 `Master_CellID_Lib`。
  - **规则：**
    - 本周期有、上周期无 → `change_type = 'New'`
    - 上周期有、本周期无 → `change_type = 'Stale'` (可能是退服或数据缺失)
  - **输出：** 新增基站/小区列表。

总结

流程分为了“统计建库”、“清洗纠偏”、“层级修正”三个核心阶段。

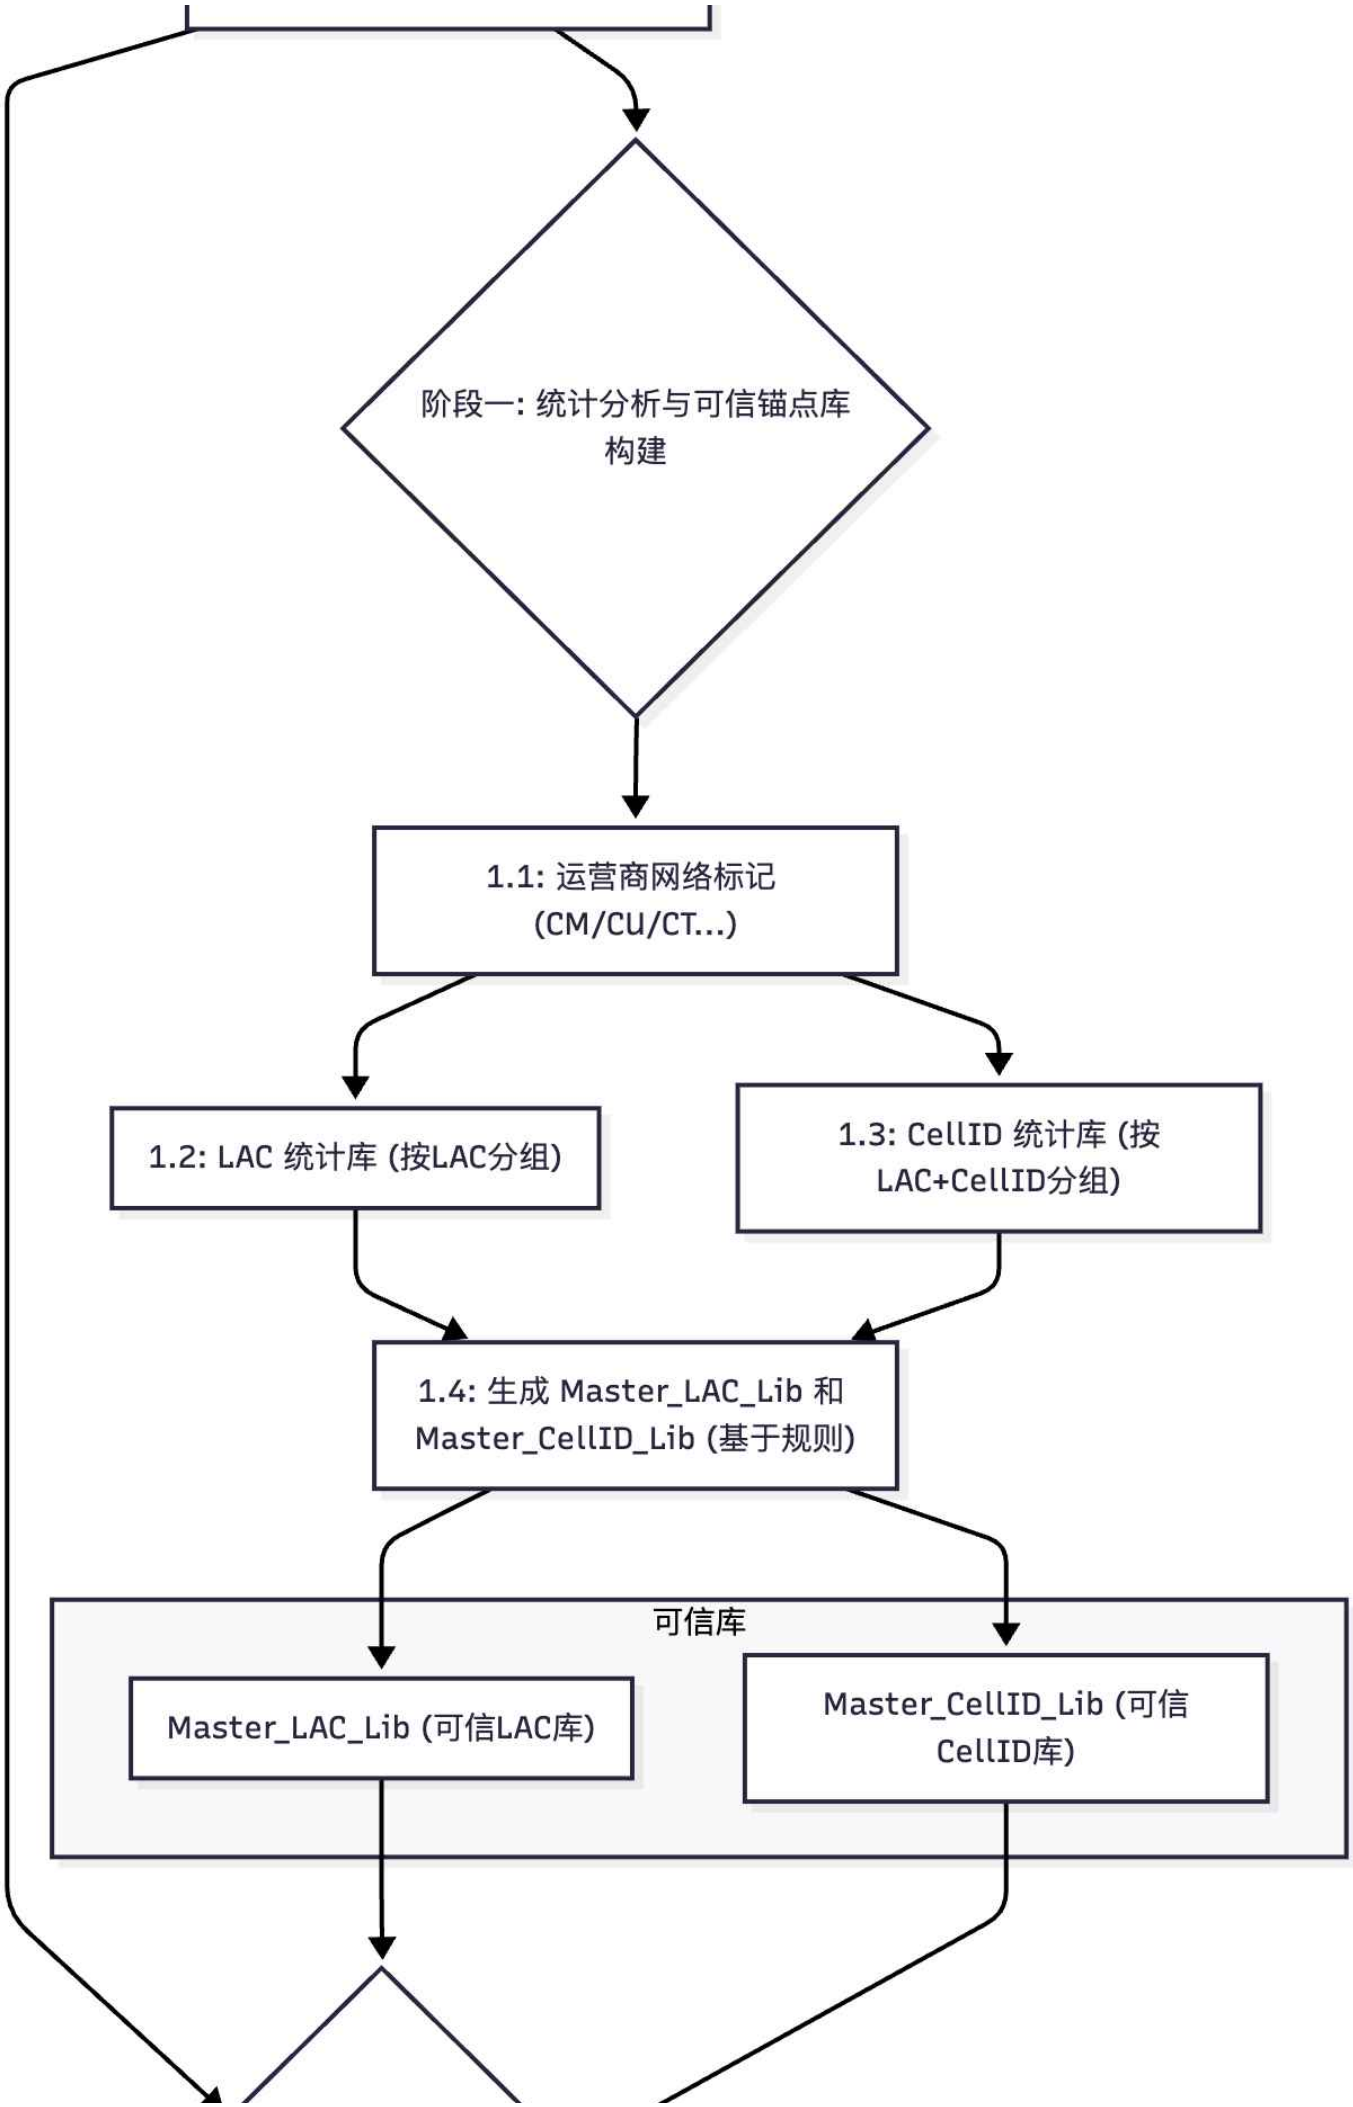
阶段一: 统计分析与可信锚点库构建
1.1: 运营商网络标记 (CM/CU/CT...)
1.2: LAC 统计库 (按LAC分组)
1.3: CellID 统计库 (按LAC+CellID分组)
1.4: 生成 Master_LAC_Lib 和 Master_CellID_Lib (基于规则)
可信库
Master_LAC_Lib (可信LAC库)
Master_CellID_Lib (可信CellID库)

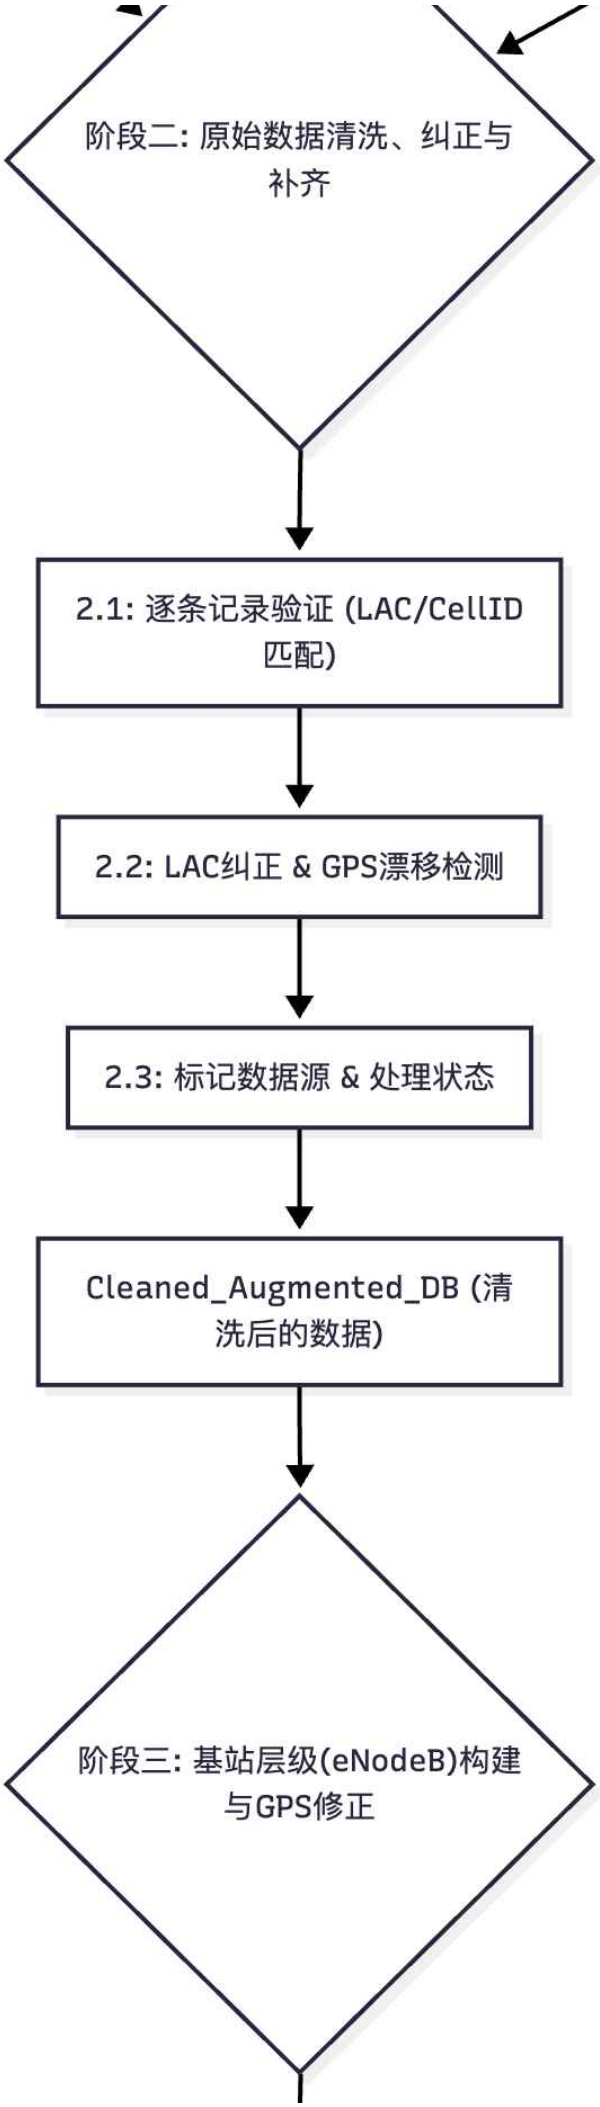
阶段二: 原始数据清洗、纠正与补齐
2.1: 逐条记录验证 (LAC/CellID匹配)
2.2: LAC纠正 & GPS漂移检测
2.3: 标记数据源 & 处理状态
Cleaned_Augmented_DB (清洗后的数据)
阶段三: 基站层级(eNodeB)构建与GPS修正

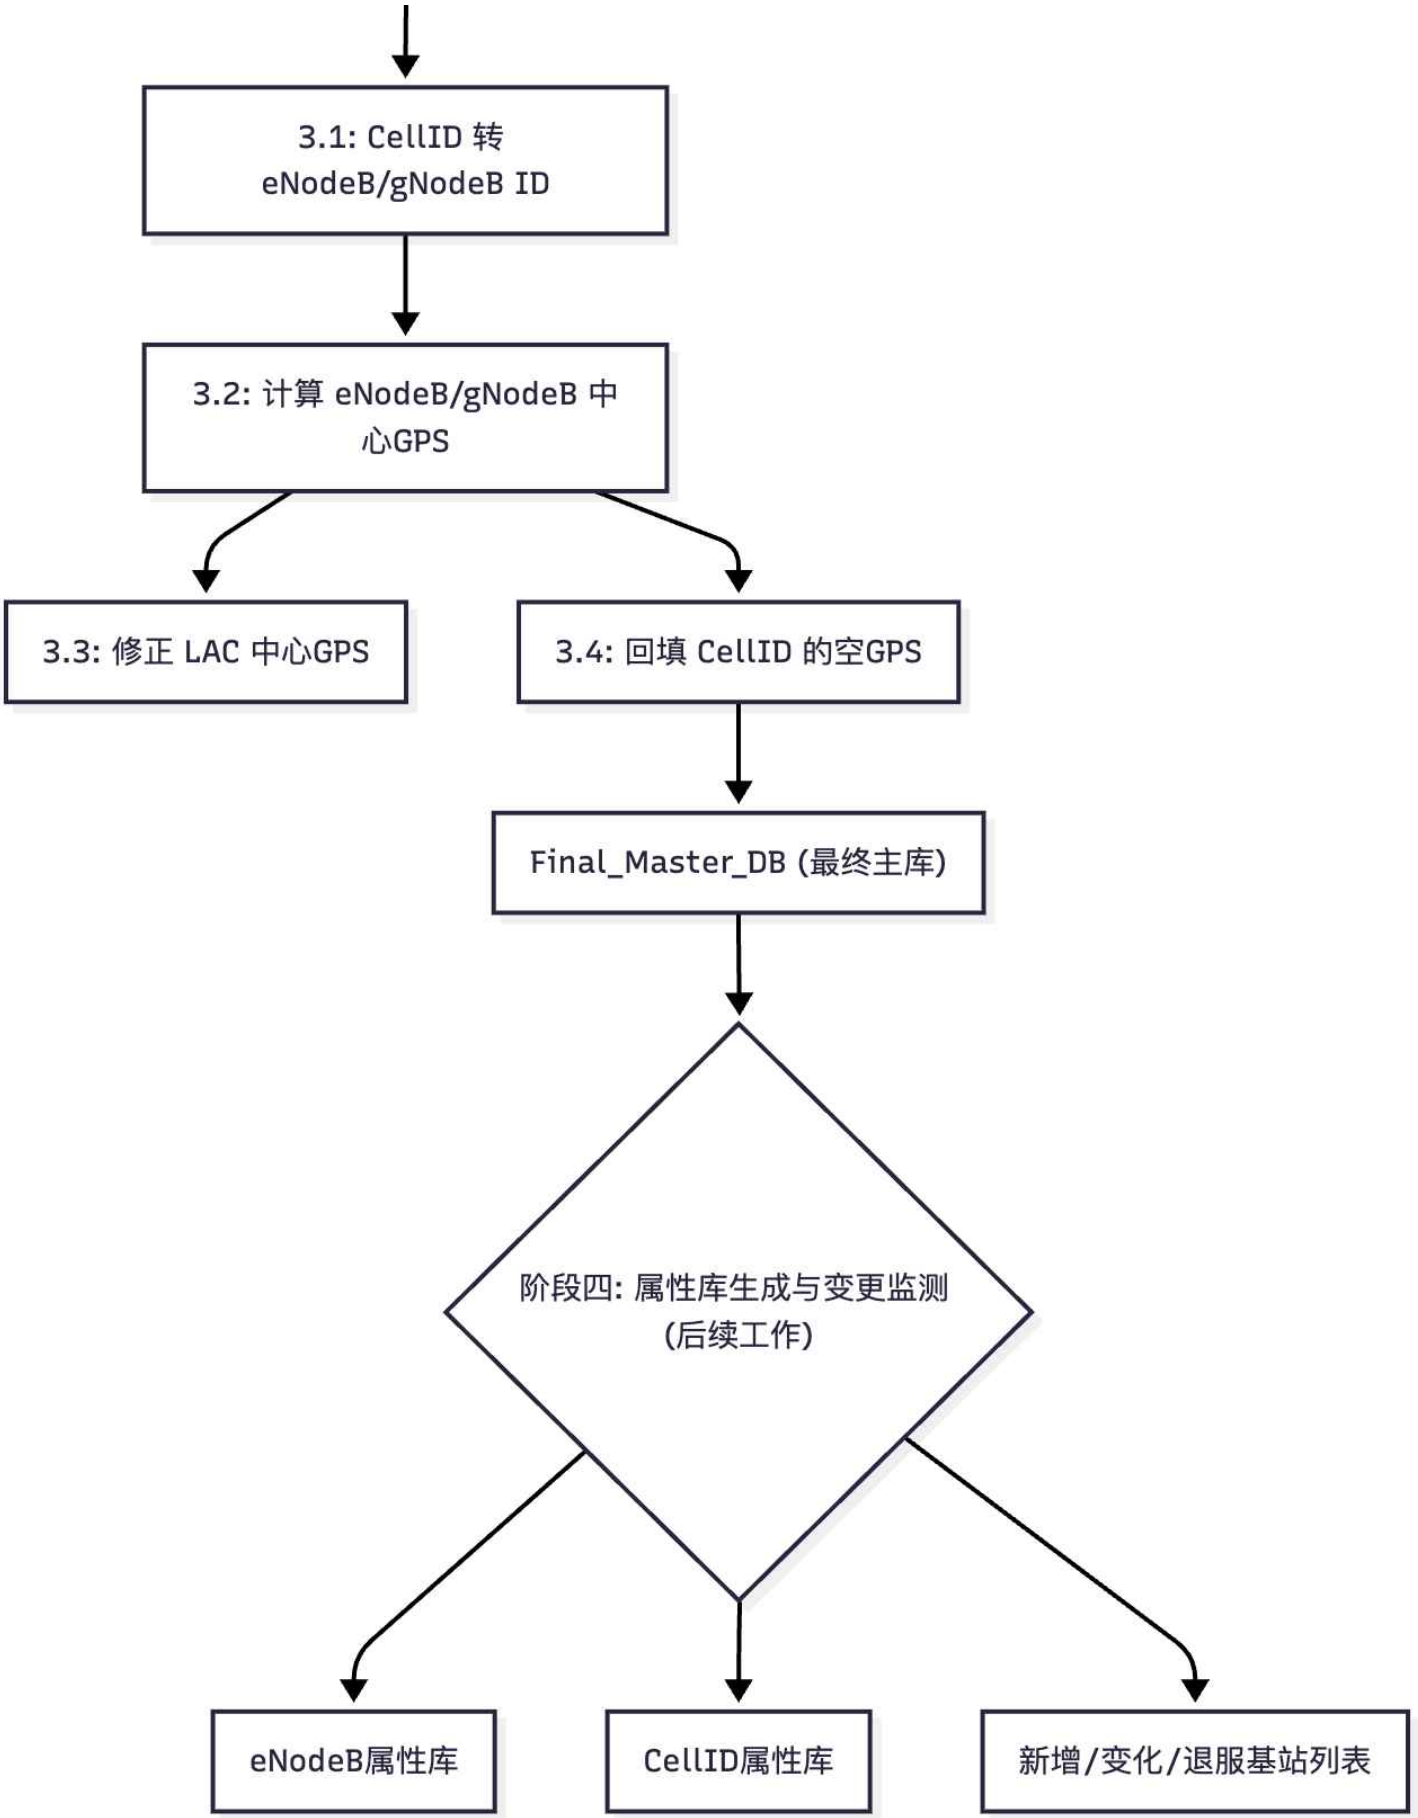

Untitled diagram-2025-11-10-070036.svg
133.23KB